

TRƯỜNG ĐẠI HỌC MỞ THÀNH PHỐ HỒ CHÍ MINH
KHOA CÔNG NGHỆ THÔNG TIN



BÁO CÁO MÔN HỌC PHÂN TÍCH DỮ LIỆU

Đề tài: DỰ ĐOÁN KHI NÀO KHÁCH HÀNG QUAY LẠI MUA HÀNG

Giáo viên hướng dẫn: ThS. Hồ Hương Thiên

Sinh viên thực hiện:

Lê Thị Minh Châu

2354050018

TP.HCM, tháng 8, năm 2026

CHƯƠNG 1: TỔNG QUAN ĐỀ TÀI

1.1 Giới thiệu về đề tài

Trong những năm gần đây, thị trường thương mại điện tử đã tạo ra những thay đổi lớn trong hành vi mua sắm của người tiêu dùng. Song song với sự phát triển đó, cạnh tranh giữa các cửa hàng trở nên ngày càng gay gắt hơn. Chi phí để thu hút khách hàng mới thường cao gấp 5-7 lần so với chi phí giữ chân khách hàng hiện tại. Vì vậy nếu cửa hàng có thể xác định khách hàng nào có khả năng quay lại, hoặc ngược lại, khách hàng nào sắp rời bỏ, thì họ có thể đưa ra các chiến lược marketing phù hợp, cải thiện dịch vụ hay điều chỉnh giá. Điều này không chỉ giúp tiết kiệm chi phí, tăng hiệu quả kinh doanh, mà còn tăng giá trị vòng đời khách hàng (customer lifetime value – CLV).

Tuy nhiên việc dự đoán hành vi quay lại mua hàng không phải lúc nào cũng đơn giản. Với số lượng khách hàng và đơn hàng lớn, việc phân tích thủ công trở nên không khả thi. Do đó, nhiều doanh nghiệp đã hướng tới phương pháp phân tích dữ liệu và học máy (machine learning) để xử lý khối dữ liệu lớn, cũng như đưa ra dự đoán chính xác hơn.

Xuất phát từ nhu cầu thực tiễn trên, đề tài: “dự đoán khi nào khách hàng quay lại mua hàng” nhằm bước đầu tìm hiểu và vận dụng các kiến thức đã học để xây dựng một mô hình đơn giản dự đoán thời điểm khách hàng có khả năng quay lại mua hàng, qua đó hiểu rõ hơn về quy trình phân tích dữ liệu khách hàng trong thực tế.

1.2 Dữ liệu

Cơ sở dữ liệu được sử dụng trong dự án nghiên cứu này là Hệ dữ liệu thực nghiệm tổng hợp nâng cao (Advanced Synthetic Benchmark Dataset), được xây dựng trong khuôn khổ chương trình đào tạo Thạc sĩ AI tại Đại học FPT. Hệ dữ liệu này được khởi tạo dựa trên các mô hình xác suất và thuật toán sinh dữ liệu tự động (như Faker, NumPy và Pandas), nhằm mô phỏng lại toàn bộ cấu trúc logic và quy trình dòng chảy thông tin (Data Flow) trong một doanh nghiệp bán lẻ đa kênh có quy mô vừa, hoạt động trong khoảng thời gian từ tháng 06/2023 đến 03/2026 (~2,75 năm)

1.3 Mục tiêu

Mục tiêu của nghiên cứu là khám phá và xác định các yếu tố trong dữ liệu có ảnh hưởng quan trọng đến khả năng khách hàng quay lại mua hàng, dựa trên hành vi giao dịch, tương tác chăm sóc khách hàng và mức độ tiếp cận các chiến dịch marketing. Từ đó, nghiên cứu xây dựng mô hình dự báo trên cơ sở sử dụng thuật toán XGBoost, đối chiếu với mô hình cơ sở Logistic Regression, nhằm dự đoán khả năng khách hàng quay lại mua hàng dựa trên các đặc trưng đã thu thập và xử lý.

Thông qua quá trình tiền xử lý dữ liệu, tích hợp đa nguồn và xây dựng đặc trưng theo phương pháp cửa sổ trượt (Sliding Window), nghiên cứu tập trung nhận diện những yếu tố có mức độ tác động lớn nhất đến hành vi quay lại của khách hàng.

Kết quả của nghiên cứu không chỉ hỗ trợ cải thiện độ chính xác của mô hình dự đoán, mà còn góp phần cung cấp những hiểu biết thực tiễn giúp doanh nghiệp bán lẻ tối ưu hóa chiến lược chăm sóc khách hàng và ra quyết định kinh doanh hiệu quả hơn.

1.4 Phương pháp

Nghiên cứu sử dụng các phương pháp phân tích dữ liệu khám phá (EDA) để tìm hiểu các đặc điểm, xu hướng trong dữ liệu khách hàng. Đồng thời kết hợp kỹ thuật xây dựng đặc trưng theo phương pháp cửa sổ trượt (Sliding Window) và phân tách dữ liệu theo thời gian nhằm tránh rò rỉ dữ liệu tương lai.

Sau đó, nghiên cứu áp dụng mô hình học máy (Machine Learning) mang tên XGBoost, đây là một thuật toán dự đoán mạnh, thường được dùng trong thực tế để dự báo hành vi khách hàng, nhằm dự đoán khả năng khách hàng sẽ rời bỏ (không quay lại mua hàng) dựa trên lịch sử mua sắm, tương tác trước đó của họ.

Nghiên cứu cũng thử một mô hình đơn giản hơn là Logistic Regression làm mô hình cơ sở đối chiếu, để làm mốc so sánh, giúp đánh giá xem mô hình chính có thực sự hiệu quả hơn hay không.

CHƯƠNG 2: KHÁM PHÁ VÀ ĐÁNH GIÁ CHẤT LƯỢNG DỮ LIỆU (EDA)

2.1 Tổng quan các tập dữ liệu

Bộ dữ liệu gồm 7 tập tin (customers, transactions, transaction_items, products, customer_support, marketing_touchpoints, stores) có quan hệ với nhau, với tổng cộng hơn 14.700 dòng dữ liệu. Chất lượng dữ liệu tốt: tỷ lệ thiếu trung bình dưới 6%, không có dòng trùng lặp.

	Tập tin	Số dòng	Số cột	Thiếu trung bình (%)	Trùng lặp	Khóa chính
0	customers.csv	800	6	3.73%	0	customer_id
1	transactions.csv	3500	6	1.69%	0	transaction_id
2	transaction_items.csv	7740	4	2.52%	0	transaction_id + product_id
3	products.csv	150	6	1.00%	0	product_id
4	customer_support.csv	700	7	5.57%	0	ticket_id
5	marketing_touchpoints.csv	1800	8	2.70%	0	campaign_id + customer_id
6	stores.csv	25	5	0.00%	0	store_id

2.2 Thống kê mô tả chi tiết

Quá trình thống kê mô tả trên 7 tập tin dữ liệu cho thấy tình trạng chất lượng dữ liệu không đồng đều, đòi hỏi các bước xử lý riêng biệt cho từng nhóm vấn đề trước khi đưa vào mô hình. Kết quả thu được của 7 tập tin như sau:

- Tập customers: Lộ diện khuyết tật dữ liệu nghiêm trọng. Biến tuổi (birth_year) chứa giá trị bất hợp lý (âm hoặc vượt xa hiện tại). Missing value rải đều mức 2% - 5% ở 5 cột khác nhau (gender, birth_year, city, registration_date, acquisition_channel).

- Tập transactions: thiếu dữ liệu nhẹ khoảng 5% ở phương thức thanh toán(payment_method) và mức giảm giá (discount_applied). Các trường Khóa nổi (Keys như transaction_id, customer_id) đầy đủ 100%.
- Tập transaction_items: số lượng (quantity) mang giá trị ÂM (min = -5). Cần bảo tồn Data này vì nghi ngờ phản ảnh hành vi Trả hàng (Refunds); thiếu ~5% ở giá tiền.
- Tập customer_support: Cột điểm hài lòng (satisfaction_score) bị thiếu dữ liệu cực nặng (Missing ~29%) và chứa các giá trị vô lý như -1 hoặc 99 (Thang đo chuẩn 'thường' chỉ 1-5).
- Tập marketing_campaigns: Cột giá trị ưu đãi (offer_value) có xuất hiện giá trị Âm (min = -50000). Các cột Boolean (is_opened, is_clicked) bị nhiễu Format nghiêm trọng với nhiều định dạng khác nhau thay vì 2.
- Tập products & stores: Cực kỳ hoàn thiện. stores không có dữ liệu bị khuyết thiếu.

2.3 Tổng hợp vấn đề dữ liệu và kế hoạch tiền xử lý

ID	Bảng dữ liệu	Cột ảnh hưởng	Loại lỗi	Mô tả / Rủi ro	Mức độ	Action Kế hoạch đề xuất
DQ-01	marketing_touchpoints	is_opened / is_clicked	Type Mismatch	Biến Bool bị gán bằng chữ ("TRUE", "Yes", "2", "-1")	Critical	Standardize về {0, 1}; Map rác thành NaN
DQ-02	customers	birth_year	Phạm vi bất hợp lý (Outliers)	Chứa giá trị âm (-1985) và siêu lớn (19990)	High	abs() cho giá trị âm, clip [1940, 2010]
DQ-03	transaction_items	quantity	Quantity < 0	Có 41 giao dịch xuất hiện số lượng Sản phẩm Âm	High	Phân tích kĩ (Là do Return?). Có thể flag riêng.
DQ-04	customer_support	satisfaction_score	Thang đo sai (Outliers)	Thang điểm rác: [-1 tới 99] thay vì [1:5]	High	Clip chặt lại trong [1, 5] hoặc NaN
DQ-05	marketing_touchpoints	offer_value	Offer Âm	Tồn tại offer_value <= 0 (thậm chí -50k)	High	Gán thành NaN đối với Offer Âm. Kẹp giới hạn cực đại.
DQ-06	transaction_items	quantity / unit_price	Mức độ thiếu Values	Trống nhiều (383 và 396 giá trị)	Medium	Xóa các sản phẩm hoặc dùng thuật toán Impute
DQ-07	customers	gender	Giá trị không hợp lệ (Noise)	Rác: 'X', '0', 'Unknown'	Medium	Gán cứng thành NaN rồi Impute mode
DQ-08	transactions	payment_method	Giá trị rác / Noise	Tồn tại 'Bitcoin', 'Gold', '???'	Medium	Gom tất cả vào tập 'Other'
DQ-09	marketing_touchpoints	sent_date	Sai định dạng thời gian	NaT, '0000-00-00', '2024/01/32'	Medium	Dùng pd.to_datetime với errors='coerce'
DQ-10	customer_support	channel	Noise Category	Gửi qua 'Fax', 'Pigeon', '###'	Low	Biến đổi thành 'Other' cho model thân thiện

CHƯƠNG 3: PHÂN TÍCH DỮ LIỆU

3.1 Tiền xử lý và tích hợp dữ liệu

Dựa trên bảng tổng hợp toàn bộ vấn đề dữ liệu, giai đoạn làm sạch dữ liệu được thực hiện theo 5 nhóm công việc chính, cụ thể :

3.1.1 Xử lý giá trị không hợp lý và tính nhất quán Logic

Đối với các giá trị mang tính "rác" xuất hiện rải rác trong dữ liệu (ví dụ phương thức thanh toán ghi là "Bitcoin", giới tính ghi là "X", hay kênh hỗ trợ ghi là "Pigeon") gom nhóm các giá trị này về một danh mục chung như "Khác" (Other) hoặc "Không xác định" (Unknown), thay vì loại bỏ hoàn toàn, nhằm giữ lại dữ liệu mà không làm sai lệch tỷ lệ phân bố.

Riêng tập tin marketing_touchpoints. Hai cột trạng thái "đã mở" và "đã nhấp chuột" vào email marketing (is_opened, is_clicked) bị ghi theo nhiều kiểu khác nhau cho cùng một ý nghĩa (ví dụ: -1, 2, "TRUE", "Yes"...). Nghiên cứu quy đổi các giá trị rõ nghĩa về đúng chuẩn nhị phân (0/1), còn giá trị bất thường không xác định được chuyển thành dữ liệu trống (NaN) để xử lý ở bước sau.

3.1.2 Xử lý giá trị dị biệt

Đối với các biến chứa dữ liệu bất thường, nghiên cứu ưu tiên khôi phục và giữ lại dữ liệu thay vì xóa bỏ, vì các giá trị này thường mang tín hiệu hành vi quan trọng.

Số lượng mua bị âm: 41 bản ghi có số lượng nhỏ hơn 0. Thay vì coi là lỗi và xóa, nghiên cứu xác định đây là các giao dịch trả hàng/hoàn tiền - một tín hiệu quan trọng cho thấy khách hàng có nguy cơ rời bỏ. Dữ liệu được giữ nguyên và gắn nhãn "đơn trả hàng"; khi tính tổng doanh thu, các giá trị âm này sẽ tự động trừ vào tổng, phản ánh đúng doanh thu thực tế.

Năm sinh bị lỗi: Một số năm sinh bị gõ sai dạng số âm (ví dụ -1985) hoặc dư số 0 (ví dụ 19990). Nghiên cứu khôi phục bằng cách lấy trị tuyệt đối với số âm, và chia 10 với số bị dư chữ số, sau đó giới hạn lại trong khoảng hợp lý (1940–2010). Cách làm này giúp tận dụng tối đa dữ liệu thay vì loại bỏ.

3.1.3 Điền khuyết dữ liệu

Tỷ lệ dữ liệu thiếu trải đều ở các bảng, dao động quanh mức 5%. Nghiên cứu áp dụng chiến lược điền khuyết riêng theo từng loại dữ liệu:


Dữ liệu dạng số (số lượng, đơn giá, năm sinh): điền bằng giá trị trung vị, vì trung vị ít bị ảnh hưởng bởi các giá trị bất thường so với giá trị trung bình.

Dữ liệu phân loại (giới tính, phương thức thanh toán...): điền bằng nhãn "Không rõ", thay vì suy đoán, vì việc khách hàng không cung cấp thông tin cũng có thể là một tín hiệu hành vi đáng lưu ý.

Dữ liệu ngày tháng (ngày gửi email, ngày đăng ký): điền bằng giá trị của dòng liền kề (trước hoặc sau), nhằm giữ đúng trình tự thời gian của dữ liệu.

Điểm hài lòng: không điền khuyết. Việc khách hàng không để lại đánh giá có thể phản ánh mức độ hài lòng thấp — nếu điền bằng giá trị trung bình sẽ làm mất đi tín hiệu cảnh báo này. Dữ liệu trống được giữ nguyên để mô hình (XGBoost) tự học từ chính sự vắng mặt đó.

3.2 Tích hợp dữ liệu



3.2.1 Phân tích mức độ giao thoa của Customer

Biểu đồ giao nhau cho thấy 800 khách hàng chia thành các nhóm:

- Nhóm 1 (402 khách hàng): vừa mua hàng, vừa nhận marketing, vừa từng liên hệ hỗ trợ nhóm dữ liệu chính để huấn luyện mô hình.
- Nhóm 2 (263 khách hàng): có mua hàng và nhận marketing, nhưng chưa từng cần hỗ trợ.
- Nhóm 3 (86 khách hàng): mua hàng dù chưa từng tiếp cận qua marketing.
- Nhóm 4 (49 khách hàng): có đăng ký nhưng chưa từng phát sinh giao dịch.

3.2.3 Lập phân hệ doanh thu

Nghiên cứu khôi phục trường Tổng doanh thu bằng công thức: $(\text{Số lượng} \times \text{Đơn giá}) \times (1 - \% \text{ Khuyến mãi})$, tính toán từ bảng transaction_items rồi tổng hợp theo từng khách hàng.

Các giao dịch có số lượng mang giá trị âm (đơn trả hàng) được giữ nguyên dấu âm, nhờ đó khi tính tổng, các khoản trả hàng sẽ tự động trừ vào doanh thu - đảm bảo phản ánh đúng doanh thu thuần thực nhận của từng khách hàng.

3.3.3 Hợp nhất đa luồng dữ liệu

Gộp toàn bộ 7/7 bảng dữ liệu thành một bảng phẳng duy nhất, lấy bảng khách hàng làm gốc, đáp ứng yêu cầu liên kết đầy đủ các file dữ liệu.

3.4 Chuẩn bị dữ liệu nâng cao cho mô hình

3.4.1 Feature Engineering (đặc trưng)

Từ dữ liệu đã làm sạch và tích hợp, nghiên cứu trích xuất các nhóm đặc trưng sau:

1. Nhóm RFM: Recency (thời gian từ lần mua gần nhất), Frequency (tần suất mua), Monetary (tổng giá trị chi tiêu) được tính từ transactions và transaction_items.
2. Hành vi mua sắm: số ngành hàng đã mua, thương hiệu ưa thích, đơn giá trung bình, tỷ lệ dùng giảm giá, xu hướng mua theo kênh (online/offline).
3. Chăm sóc khách hàng: số lượng ticket hỗ trợ, tỷ lệ được giải quyết, điểm hài lòng trung bình.
4. Hiệu suất marketing: tỷ lệ mở/nhấp email, tần suất nhận chiến dịch, tổng giá trị ưu đãi nhận được.
5. Đặc trưng thời gian: ngày trong tuần thường mua hàng, khoảng cách trung bình giữa các lần mua.

Để tránh rò rỉ dữ liệu và đảm bảo đủ kích thước mẫu huấn luyện, nghiên cứu áp dụng phương pháp cửa sổ trượt (Sliding Window) tại ba mốc thời gian lùi dần (30, 60, 90 ngày), giúp mở rộng tập dữ liệu từ 800 lên 2.400 bản ghi và phản ánh được sự thay đổi hành vi khách hàng theo thời gian.

3.4.2 Target Label (nhãn dự đoán)

Biến mục tiêu will_return_within_30_days là bài toán phân loại nhị phân, xác định khách hàng có phát sinh giao dịch trong vòng 30 ngày kể từ mốc quan sát hay không. Đặc trưng đầu vào và nhãn dự đoán được tách biệt theo thời gian nhằm tránh rò rỉ dữ liệu.

Với các trường hợp thiếu dữ liệu do đặc thù hành vi khách hàng (ví dụ chỉ mua một lần), nghiên cứu giữ nguyên giá trị trống thay vì điền số liệu thay thế, để mô hình XGBoost tự xử lý. Dữ liệu tại mốc gần nhất (T-30) được dùng làm tập kiểm thử, còn việc huấn luyện chủ yếu dựa trên các mốc thời gian còn lại.

	snapshot_label	will_return_within_30_days	recency_days	frequency_total	monetary_total
0	T-30	0	22.0	10.0	1.185411e+07
800	T-60	1	3.0	9.0	9.857651e+06
1600	T-90	1	69.0	8.0	1.053640e+07

kết quả: cùng một khách hàng được quan sát tại ba thời điểm khác nhau, tạo ra ba bản ghi độc lập với đặc trưng hành vi và nhãn dự đoán khác nhau. Đã tái tạo thành công một mạng lưới Hành vi Khách hàng vô cùng mạnh mẽ.

CHƯƠNG 4: XÂY DỰNG VÀ ĐÁNH GIÁ MÔ HÌNH

4.1 Xây dựng mô hình

4.1.1 Huấn luyện mô hình

Quá trình huấn luyện mô hình được thực hiện theo các bước sau:

Phân chia dữ liệu theo thời gian: Do đặc thù dữ liệu chuỗi thời gian, nghiên cứu không chia tập huấn luyện/kiểm tra theo cách ngẫu nhiên thông thường, nhằm tránh rò rỉ dữ liệu tương lai. Thay vào đó, dữ liệu tại hai mốc quan sát xa hơn (T-90, T-60) được dùng làm tập huấn luyện, còn dữ liệu tại mốc gần nhất (T-30) được dùng làm tập kiểm tra.

Lựa chọn mô hình: Nghiên cứu khởi tạo mô hình Logistic Regression làm mô hình cơ sở (baseline), sau đó huấn luyện mô hình XGBoost nhằm cải thiện khả năng xử lý các mối quan hệ phi tuyến tính giữa các đặc trưng.

Tối ưu tham số: Phương pháp GridSearchCV được áp dụng trên mô hình XGBoost để tìm bộ tham số phù hợp nhất, thông qua 108 lượt huấn luyện chéo (3-fold cross-validation trên 36 tổ hợp tham số). Bộ tham số tối ưu thu được là `learning_rate = 0.01`, `max_depth = 3`, `n_estimators = 100`, `subsample = 0.8`.

Chỉ số đánh giá: Do dữ liệu có sự mất cân bằng giữa hai nhóm khách hàng (quay lại/rời bỏ), nghiên cứu sử dụng ROC-AUC làm chỉ số đánh giá chính, kết hợp với Accuracy, Recall và Precision để đánh giá toàn diện hơn.

4.1.2 Kết quả

So sánh 2 mô hình:

Chỉ số	Logistic Regression	XGBoost (Tuned)	Nhận xét
ROC-AUC	0.675	0.672	Gần ngang nhau: cả hai phân biệt được churn/retain ở mức khá
Accuracy	0.65	0.71	XGBoost vượt 6% nhờ phân loại đúng Churn tốt hơn
Churn Recall	0.67	0.77	XGBoost bắt thêm ~64 ca Churn mà Logistic bỏ sót
Retain Recall	0.60	0.46	Đánh đổi: XGBoost bỏ sót nhiều KH quay lại hơn
Retain Precision	0.31	0.33	Cả hai đều thấp: cứ 3 lần đoán "sẽ quay lại" thì sai 2 lần


4.2 Đánh giá mô hình

== BASELINE: LOGISTIC REGRESSION ==				
	precision	recall	f1-score	support
0 (Churned)	0.87	0.67	0.76	643
1 (Retained)	0.31	0.60	0.40	157
accuracy			0.65	800
macro avg	0.59	0.63	0.58	800
weighted avg	0.76	0.65	0.69	800

== OPTIMIZED MODEL: XGBOOST ==				
	precision	recall	f1-score	support
0 (Churned)	0.85	0.77	0.81	643
1 (Retained)	0.33	0.46	0.39	157
accuracy			0.71	800
macro avg	0.59	0.62	0.60	800
weighted avg	0.75	0.71	0.73	800


Ở mô hình cơ sở, độ chính xác tổng thể (accuracy) đạt 0,65. Mô hình dự đoán khá tốt nhóm khách hàng rời bỏ (Churn) với precision 0,87 và F1-score 0,76, nhưng hoạt động kém hơn nhiều ở nhóm khách hàng quay lại (Retain), với precision chỉ 0,31 dù recall đạt 0,60. Điều này cho thấy mô hình có xu hướng thiên lệch về việc dự đoán đúng nhóm chiếm đa số (Churn), trong khi nhóm thiểu số (Retain) khó dự đoán chính xác hơn.

So với mô hình cơ sở, XGBoost cải thiện độ chính xác tổng thể lên 0,71 và tăng đáng kể khả năng phát hiện đúng nhóm Churn (recall từ 0,67 lên 0,77, F1-score từ 0,76 lên 0,81). Tuy nhiên, sự cải thiện này đánh đổi bằng việc giảm khả năng phát hiện nhóm Retain (recall giảm từ 0,60 xuống 0,46). Nhìn chung, XGBoost phù hợp hơn nếu mục tiêu ưu tiên là phát hiện đúng khách hàng có nguy cơ rời bỏ để can thiệp sớm.



Mô hình XGBoost dự đoán đúng 494/643 khách hàng thực tế rời bỏ (tỷ lệ phát hiện đúng khoảng 77%), cho thấy khả năng nhận diện nhóm này khá tốt. Đối với nhóm khách hàng thực tế quay lại, mô hình chỉ dự đoán đúng 73/157 trường hợp (khoảng 46%), còn 84 trường hợp bị dự đoán nhầm thành rời bỏ. Kết

quả này phản ánh mô hình còn hạn chế trong việc nhận diện đúng nhóm khách hàng trung thành, một phần do số lượng mẫu của nhóm này ít hơn đáng kể so với nhóm rời bỏ trong tập dữ liệu.



Tần suất và nhịp độ mua sắm là hai tín hiệu hành vi quan trọng nhất để dự đoán khả năng khách hàng quay lại, hơn cả các yếu tố nhân khẩu học (giới tính, kênh thu hút khách hàng) hay chỉ số chăm sóc khách hàng. Đáng chú ý, các đặc trưng liên quan đến hỗ trợ khách hàng (resolved_rate) và tỷ lệ mua online (online_shopping_ratio) gần như không có đóng góp vào mô hình.

KẾT LUẬN

Mô hình XGBoost đã chỉ ra rằng khách hàng **không rời bỏ vì dịch vụ chăm sóc tệ** (các chỉ số total_tickets, resolved_rate gần như vô nghĩa). Thay vào đó, lý do cốt lõi nằm ở **thói quen mua sắm bị gián đoạn**:

- Khách mua **ít lần** (frequency_total thấp) có nguy cơ Churn cao nhất
- Khoảng cách giữa các lần mua **càng xa** (inter_purchase_interval cao), xác suất rời bỏ càng lớn
- Khách chỉ mua **một loại sản phẩm duy nhất** (unique_categories thấp) dễ rời bỏ hơn khách mua đa dạng